


$$a) \exists L(y, a(x)) = g(y - a(x)) \quad |y - a(x)|$$

$$b) g(0) = 0$$

$$\rightarrow c) |z_1| < |z_2| \Rightarrow g(z_1) \leq g(z_2)$$

$$2) g - 2 \wedge A g \text{ KAI}$$



$$L(y, a(x)) = g(y - a(x)) \approx$$

$$\approx \underbrace{g(0)}_0 + \underbrace{g'(0)}_0 \cdot (y - a(x)) + \frac{g''(0)}{2} (y - a(x))^2 =$$

$$= c \cdot (y - a(x))^2$$

Вероятностный подход:  $ММР \rightarrow \varphi. \text{ошибки}$

$$(-1) \cdot \log P(y|x, \theta) \rightarrow \min_{\theta}$$

упр.

$$y = \langle w, x \rangle + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad \mu$$

$$y|x \sim \mathcal{N}(\langle w, x \rangle, \sigma^2)$$

$$P(y|x, \theta) \quad \theta = (w, \sigma^2)$$

$$P(t) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(t-\mu)^2}{2\sigma^2}\right)$$

$$L(w) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left(-\frac{(y_i - \langle w, x \rangle)^2}{2\sigma^2}\right) \rightarrow \max_{\theta}$$

$$\ell_n L(w) = -n \log \sqrt{2\pi\sigma^2} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \langle w, x \rangle)^2$$

$$\ell_n L(w) \propto \underbrace{-\frac{1}{n} \sum (y_i - \langle w, x \rangle)^2}_{\text{MSE}}$$


— MSE

Выводы:

- Нормальный шум соответствует MSE, нормальное распределение не предполагает выбросов

- Лапласовский шум соответствует MAE, он предполагает наличие выбросов (хвосты распределения толще)  $\Rightarrow$  модель с MAE может нормально работать с выбросами и не обращать на них внимание

Yhp.



$$P(y_i = k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

$$\lambda(x_i) = \text{модель} \\ \langle w, x \rangle$$

системы

$$L(w) = P(y | x, w) = \prod_{i=1}^n \frac{e^{-\lambda(x_i)} \cdot (\lambda(x_i))^{y_i}}{y_i!}$$

$$(-1) \cdot \log L(w) \propto \sum (y_i \log \lambda(x_i) - \lambda(x_i) - \log y_i!)$$

$$\rightarrow \text{poiss loss} = \frac{1}{n} \sum [\lambda(x_i) - y_i \cdot \log \lambda(x_i)] \rightarrow \min_w$$

Когда мы доберемся до рекомендательных систем и будем говорить про ALS (матричные разложения), эта функция потерь ещё у нас всплывёт

YhP.

Y	0	1
P	1-p	p

$$y_i = 1 \quad 10 \text{ раз}$$

$$y_i = 0 \quad 5 \text{ раз}$$


$$L(p) = p^{10} (1-p)^5$$

$$p^{\sum y_i} (1-p)^{n - \sum y_i}$$

$$y = wx$$

$$F(wx)$$

$$F(t) = \frac{1}{1 + e^{-t}}$$



$$P_i = P(y_i = 1 | x) = F(\langle w, x_i \rangle + w_0)$$

$y_i$	0	1
	$1 - P_i$	$P_i$

$$L = p_1^{y_1} \cdot (1 - p_1)^{1 - y_1} \cdot \dots \cdot p_n^{y_n} \cdot (1 - p_n)^{1 - y_n}$$

$$\log L \propto \frac{1}{n} \sum [y_i \ln p_i + (1 - y_i) \ln (1 - p_i)]$$

$$\log \text{loss} \propto -\log L \rightarrow \min_w$$

$$y_i \in \{0, 1\}$$

$$y_i \in \{-1, 1\}$$

$$y_i \log p_i + (1 - y_i) \log (1 - p_i)$$

$$\log [1 + \exp(y_i \langle w, x_i \rangle)]$$

ММП обладает кучей хороших асимптотических свойств

Это работает если

$$\frac{h}{d} \rightarrow \infty$$

$$\boxed{\frac{h}{d} < 1}$$

в жизни  $\parallel$

$\Rightarrow$

из т.н.  
регуляризация

## 2. Байесовский и частотный подходы

### Частотный

$\theta$  — неизвестная константа

Данные:  $y_1, \dots, y_n$

Модель: описывает связь параметров и данных

ММП  $\hat{\theta}^{ML}$

$\hat{\theta}^{ML} \sim \mathcal{N}(\dots)$

$[\theta^L \theta^R]$

АБ-Тест

$\hat{\theta} \xrightarrow{\text{модель}} \hat{y}_{n+1}$

### Байесовский


$\theta$  — случайная величина

Данные:  $y_1, \dots, y_n$

Ровно те же самые модели что и в частотном подходе

Байесовский  
вывод

$p(\theta|y)$



$P(y|x, \theta)$  — правдоподобие

$P(\theta)$  — априорное распределение

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$P(\theta|x, y)$  — апостериорное распределение

$$P(\theta|x, y) = \frac{P(y, \theta|x)}{P(y|x)} = \frac{P(y|\theta, x) \cdot P(\theta)}{P(y|x)}$$

не  
зависит  
от  $\theta$


$$\int P(y, \theta|x) d\theta = P(\theta) \cdot P(y|x)$$

$$P(\theta|x, y) \propto P(y|\theta, x) \cdot P(\theta)$$

Байес для бедных:

- апостериорное распределение искать дорого, зато легко найти его моду

$$\hat{\theta}^{MAP} = \text{Mod}(\theta|x, y)$$



$$P(\theta|x, y) \rightarrow \max_{\theta}$$

$$\ln P(\theta|x, y) = \ln P(y|\theta, x) + \ln P(\theta) \rightarrow \max_{\theta}$$


$$P(\theta) = 1 \quad \theta \sim U[-\infty; +\infty] \quad \hat{\theta}^{MAP} = \hat{\theta}^{ML}$$

$$(-1) \cdot \text{posterior} = -\text{likelihood} + -\text{prior} \\ L(y, \theta) + R(\theta) \rightarrow \min_{\theta}$$

yhp.

$$y = \langle w, x \rangle + \varepsilon \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

$$w_j \sim \mathcal{N}(0, \alpha^2)$$



↓ макс.  
↓ variance

$$P(w|y, x) \propto P(y|x, w) \cdot P(w) \rightarrow \max_w$$

$$-\ln P(w|y, x) \propto \frac{1}{2\sigma^2} \sum (y_i - \langle w, x_i \rangle)^2 + \frac{1}{2\alpha^2} \sum w_j^2 \rightarrow \min_w$$

$$\text{MSE} + \frac{\sigma^2}{\alpha^2} \cdot \|w\|^2$$

$$\sigma^2 = 1$$

$$1/\alpha^2 = \lambda$$

Ridge

что такое LASSO?

Ynp.

$y_1$  - только одно значение.


$$y = w$$

Ridge

$$Q = (y_1 - w)^2 + \lambda \cdot w^2 \rightarrow \min_w$$

$$-2(y_1 - w) + 2\lambda w = 0$$

$$\hat{w}^A = \frac{y_1}{1+\lambda}$$



LASSO

$$Q = (y_1 - w)^2 + \lambda \cdot |w| \rightarrow \min_w$$

$$-2(y_1 - w) + \lambda \cdot \text{sgn } w$$

•  $w > 0$        $w^+ = y_1 - \frac{\lambda}{2} \Leftrightarrow y_1 > \frac{\lambda}{2}$

•  $w < 0$        $w^- = y_1 + \frac{\lambda}{2} \Leftrightarrow y_1 < -\frac{\lambda}{2}$

$y_1 + \frac{\lambda}{2} < 0$

$y_1 \in [-\frac{\lambda}{2}; \frac{\lambda}{2}]$  ???  $w = 0$

$w^- > w^+ \quad \lambda \neq 0$


$$Q = y_1^2 - 2y_1 w + w^2 \pm \lambda \cdot \text{sgn } w \cdot w$$

$$w^2 - (2y_1 \mp \lambda) w + y_1^2$$


$$a w^2 + b w + c$$

находим

$w^+ > 0$ ✓	$w^+ < 0$ ②
$w^- > 0$	$w^- < 0$ ✓
$w^+ < 0$	$w^+ > 0$
$w^- > 0$ 0	$w^- < 0$ 0



$w > 0$



$$\hat{w} = \begin{cases} y_1 - \frac{\lambda}{2}, & y_1 > \frac{\lambda}{2} \\ y_1 + \frac{\lambda}{2}, & y_1 < -\frac{\lambda}{2} \\ 0 & \text{иначе} \end{cases}$$

