


① BVD гэж Регрессия зөвлөх

$$E_{x,\varepsilon} [\gamma(x, \varepsilon) - \alpha(x, X)]^2 = \text{bias}_X^2[\alpha(x, X)]$$

$$= \sigma^2 + \text{Var}_X(\alpha(x, X)) + (\hat{\alpha}(x) - E_X[\alpha(x, X)])^2$$

Информация

$$f(x) = w \cdot x$$

$$\gamma(x, \varepsilon) = w \cdot x + \varepsilon$$

$$(\gamma(x, \varepsilon) - \alpha(x, X))^2$$

$$\hat{w} = \frac{\sum x_i y_i}{\sum x_i^2}$$

такое
распределение

$$\alpha(\tilde{x}, X) = \gamma \cdot \frac{\sum x_i y_i}{\sum x_i^2} \cdot \tilde{x}$$

из
однородной
выборки

Вероятностный эндоген:

$$\varepsilon \sim N(0, \sigma^2)$$

$$x \sim N(0, \lambda^2)$$

Так как ε имеет агрегат
с извращением

x - генерализовать

Найдите γ :
коэффициент MSE

$$\begin{aligned} \text{Var}_{x,\varepsilon}(\alpha(\tilde{x}, X)) &= \gamma^2 \tilde{x}^2 \cdot \frac{1}{(\sum x_i^2)^2} \cdot \sum x_i^2 \cdot \text{Var}_{x,\varepsilon}(y_i) = \\ &= \gamma^2 \tilde{x}^2 \cdot \frac{\sigma^2}{\sum x_i^2} \end{aligned}$$

$$y_i: \mathbb{E}[\varepsilon_i] = 0 \quad \underbrace{wx_i + \varepsilon_i}$$

$$\begin{aligned} E_x[\alpha(\tilde{x}, X)] &= E_x \left[\gamma \cdot \frac{\sum x_i [wx_i + \varepsilon_i]}{\sum x_i^2} \cdot \tilde{x} \right] = \\ &= \gamma \cdot \tilde{x} \cdot w \end{aligned}$$

$$\text{bias}_x[\alpha(\tilde{x}, X)] = \gamma \tilde{x} w - \hat{x} w$$

$\gamma = \$ \Rightarrow$ negative bias

$$E_{x,\varepsilon} \left[y - \underbrace{E(y|x)}_{wx} \right]^2 = \text{Var}_{x,\varepsilon}(y) = \sigma^2$$

$$\text{MSE} = \sigma^2 + (\gamma \tilde{x} w - \hat{x} w)^2 + \gamma^2 \tilde{x}^2 \cdot \frac{\sigma^2}{\sum x_i^2} \rightarrow \min \gamma$$

$$2 \tilde{x} w (\gamma \tilde{x} w - \hat{x} w) + 2 \gamma \tilde{x} \cdot \frac{\sigma^2}{\sum x_i^2} = 0$$

$$w^2 \cancel{\gamma} \cancel{\tilde{x}} + \gamma \tilde{x} \cdot \frac{\sigma^2}{\sum x_i^2} = 0$$

$$\gamma = \frac{w^2}{w^2 + \frac{\sigma^2}{\sum x_i^2}} = \frac{1}{1 + \frac{\sigma^2 / \sum x_i^2}{w^2}} \neq 1$$

$$\frac{\text{Var}(\hat{w})}{E(\hat{w})^2} = \frac{\sigma^2}{w^2}$$

$$\Rightarrow \exists \gamma \neq \$$$

$$\text{bias}_x(\alpha(\tilde{x}, X)) > 0$$

$$\text{Var}_x(\alpha(\tilde{x}, X)) \downarrow$$

Задачи

$$y(x, \varepsilon) = w \cdot x + \varepsilon$$

$$\hat{w}^{\text{Ridge}} = \frac{\sum_i x_i y_i}{\sum_i x_i^2 + \lambda} \quad \sum_i (y(x, \varepsilon) - a(x, X))^2 + \lambda w^2 \rightarrow \min_w$$

$$\lambda - ?$$

$\lambda \approx 0$ для устойчивости

Объекты попарно как связать x и y

$$\mathbb{E}_{x, \varepsilon} [y(x, \varepsilon) - a(x, X)]^2 = \dots \rightarrow \min_{\lambda}$$

$$\Rightarrow \lambda^* = \dots$$

Для того чтобы λ^* было близко к 0

применение

сходимость \uparrow
разброс $\downarrow \Rightarrow \text{MSE} \downarrow$

Рекомендации

интерпретир.

- сдвиг = 0 Эквивалент
- Понятна расчленяется
ML-алгоритм
- LIME
- SHAP

② Дзэрнүүлүү

$b_n(x)$ - сандырмалык алгоритм (кеэзбасылык
гана ор гана)

$$\alpha_N(x) = \frac{1}{N} \sum_{j=1}^N b_j(x)$$

Пәнжүүлүү x_{train}

Түрлөг жана сүйснөөк иштөө **жадалыктай** ал.

Хоюу беңеңдөө \Rightarrow MSE болуп

$$\text{Var}_X(\alpha_N(x, X))$$
 болуп

$$\begin{aligned} \text{Var}_X(\alpha_N(x, X)) &= \frac{1}{N^2} \cdot \sum_{j=1}^N \text{Var}_X[b_j(x, X)] = \\ &= \frac{1}{N^2} \cdot N \cdot \text{Var}_X b_j(x, X) = \underbrace{\text{Var}_X(b_j(x, X))}_{N} \end{aligned}$$

Дисперсиян неге N пән

$$\begin{aligned} \text{bias}_X(\alpha_N(x, X)) &= f(x) - \mathbb{E}_X[\alpha_N(x, X)] = \\ &= f(x) - \frac{1}{N} \sum_{j=1}^N \mathbb{E}_X[b_j(x, X)] = f(x) - \mathbb{E}[b_j(x, X)] = \\ &= \text{bias}_X[b_j(x, X)] \end{aligned}$$

Сама жадалык таңдаудан

\Rightarrow MSE та текте

Сыр. nec — разбить регион ближе глядя на
данные.

Тщательное дерево

↓ синег.

↑ разброс

③ Достигнутое в задаче пересечения

$$a_n(x) = \sum_{j=1}^N b_j(x)$$

Каждая листовая логика
исправляет ошибки
предыдущих узлов

1923 Jerome Friedman

А-семейство алгоритмов (дерево)

Оптимизируя MSE

$$\frac{1}{2} \sum_{i=1}^n [a(x_i) - y_i]^2 \rightarrow \min_a$$

$$a_n(x) = \sum_{j=1}^N b_j(x)$$

$$b_1(x) = \arg \min_{b \in A} \frac{1}{2} \sum_{i=1}^n (b(x_i) - y_i)^2$$

$$S_i^{(1)} = y_i - a_1(x_i) \quad \text{"ошибки"}$$

$$b_2(x) = \arg \min_{\beta \in \mathcal{A}} \frac{1}{2} \sum_{i=1}^n (\beta(x_i) - s_i^{(1)})^2$$

$$\alpha_2(x) = \underbrace{b_1(x)}_{\text{свершил}} + \underbrace{b_2(x)}_{\text{предсказывает}}$$

ошибку
 $s_i^{(1)}$
 определяет
 ошибку $s_i^{(1)}$ и
 фиксирует её

$$s_i^{(2)} = y_i - \alpha_2(x_i)$$

$$b_3(x) = \arg \min_{\beta \in \mathcal{A}} \frac{1}{2} \sum_{i=1}^n (\beta(x_i) - s_i^{(2)})^2$$

$$\alpha_3(x) = \alpha_2(x) + b_3(x)$$

• • • •

$$s_i^{(n)} = y_i - \alpha_{N-1}(x_i) = y_i - \sum_{j=1}^{N-1} b_j(x_i)$$

$$b_N(x) = \arg \min_{\beta \in \mathcal{A}} \frac{1}{2} \sum_{i=1}^n (\beta(x_i) - s_i^{(n)})^2$$

"Остаться" s_i в оценке сдвигает её ближе к истинной величине, корректируя предыдущую ошибку на противоположную.

$$s_i^{(n)} = -\frac{\partial}{\partial z} \left[\frac{1}{2} \left(y_i - z \right)^2 \right] \Big|_{z=\alpha_{N-1}(x_i)} = y_i - \alpha_{N-1}(x_i)$$

4) Графическая методика

$L(y, z)$ — функция потерь

$$a_n(x) = \sum_{j=0}^n \gamma_j \cdot b_j(x) — \text{взвешеная сумма}$$

базовых алгоритмов

$b_0(x)$ — начальный прогноз

$$\begin{aligned} \gamma_0 &= 1 \\ b_0 &= 0 \\ b_0 &= \bar{y} \\ b_0 &= \text{стартовое значение} \end{aligned}$$

занес
само
значение
класа

...

Задача минимизировать $a_{n-1}(x) + \gamma_n \cdot b_n(x)$

$$\sum_{i=1}^n L(y_i, a_{n-1}(x_i) + \gamma_n \cdot b_n(x)) \rightarrow \min_{\gamma_n \in \mathcal{A}}$$

b_n — новый прогноз на основе!

$$\sum_{i=1}^n L(y_i, a_{n-1}(x_i) + \gamma_n \cdot s_i) \rightarrow \min_{s_1, s_2, \dots, s_n}$$

Для MSE задачи $s_i = y_i - a_{n-1}(x_i)$

Уменьшить коэффициент потерь, $L(y, z)$

$$s_i = -\frac{\partial L}{\partial z} \Big|_{z=a_{n-1}(x_i)}$$

$$b_n(x) = \arg \min_{b \in \mathcal{A}} \sum_{i=1}^n (b(x_i) - s_i)^2$$

Использование оз L для минимизации

\Rightarrow Всегда одна и та же сума MSE

$$\gamma_n = \arg \min_{\gamma \in \mathbb{R}} \sum_{i=1}^n L(y_i, a_{n-1}(x_i) + \gamma \cdot b_n(x_i))$$

Классификационный GBM

$$a_n(x) = \sum_{j=1}^r b_j(x) \cdot \gamma_j$$

b_0 - решающее, $\gamma_0 = 1$

Обычно N -ой итерации:

$$s_i = -\frac{\partial L(y_i, z)}{\partial z} \quad | \quad z = a_{n-1}(x)$$

Чтобы близко находить x , забывая о b .
Т.к. учитывает b предыдущий, а в текущем можно просто корректировать b независимо от x .

Направление, когда ошибка сблизится к конфигурации x_i , чтобы ошибка уменьшилась

$$\textcircled{1} \quad \frac{1}{n} \sum_{i=1}^n (b_n(x_i) - s_i)^2 \rightarrow \min_{b_n}$$

$$\textcircled{2} \quad \frac{1}{n} \sum_{i=1}^n L(y_i, a_{n-1}(x_i) + \gamma_n b_n(x_i)) \rightarrow \min_{\gamma_n}$$

⑤ Регрессия

Быть может не подходит

- Следующие — Быть может ↓ это game of chance базовых при.
- Разброс — может ↓ из-за переобучения

Помощь: брать следующие изучи с маленькими разбросами

⇒ Общую формулу называют деревьями

- Изучите базовое дерево
- Изучите дерево в
- Структура дерева

Xgboost catboost light GBM

Они предлагают разные регрессии и различные способы улучшить деревья

Общее:

Следующий шаг в обучении \Rightarrow шаги к окончанию обучения

или повторять

$$a_n(x_i) = a_{n-1}(x_i) + \underbrace{\eta}_{\text{learning rate}} \cdot y_n \cdot b_n(x_i)$$

learning rate

$$\eta \in [0, 1]$$

Типу $y \downarrow$ шаги $\uparrow N$

График ошибки


$$L(y, z) = |y - z| = \begin{cases} y - z, & z < y \\ z - y, & z \geq y \end{cases}$$

$$S_i = - \frac{\partial L}{\partial z} (|y - z|) \Big|_{z = a_{N-1}(x)} =$$

$$= \begin{cases} 1, & z < y \\ -1, & z \geq y \end{cases}$$

$$y_1 = 0 \quad a_{N-1}(x_1) = 5 \quad L = 5$$

$$y_2 = 0 \quad a_{N-1}(x_2) = 50 \quad L = 50$$



Максимальное значение ошибки

$$S_1 = \text{Sign}(0 - 5) = -1$$

При этом получается
к нравившемуся ответу
не обратное значение
на разные ошибки


$$S_2 = \text{Sign}(0 - 50) = 1$$

Информативные

$$L(y, z) = \frac{1}{2}(y - z)^2$$

$$S_i = -\frac{\partial L}{\partial z} \Big|_{z=a_{N-1}(x_i)} = (y - a_{N-1}(x_i))$$

| y_i | 5 | 3 | -2 |
|----------------|---|----|----|
| $a_{N-1}(x_i)$ | 4 | 8 | -1 |
| S_i | 1 | -5 | -1 |



$$\sum (b_N(x_i) - S_i)^2 \rightarrow \min_b$$

$$a_N(x_i) = a_{N-1}(x_i) + b_N(x_i)$$

Методика
серебряной
сечки
регрессии
дополнение
маленькой до нуля

Упрощение

$$L(y, z) = \frac{1}{2} (10 \cdot [z \geq y] + [z < y]) \cdot (y - z)^2$$

$$\begin{array}{lll} y_1 = 0 & \alpha_{N-1}(x) = 5 & L = 125 \\ y_2 = 0 & \alpha_{N-1}(x) = -5 & L = 12.5 \end{array} \quad \left| \begin{array}{l} \text{Параметр } b \\ \text{ио паз} \end{array} \right.$$

$$s_i = - \frac{\partial L(y, z)}{\partial z} \Big|_{z=\alpha_{N-1}(x_i)} = \frac{(10 [z \geq y] + [z < y]) \cdot (y - z)}{(y - z)}$$

$$\begin{array}{ll} s_1 = -50 & \text{исгем сонбие} \\ s_2 = 5 & \Rightarrow \text{старт за } l^{\text{ст}} \text{ наложени} \end{array}$$

$$\text{Даные} - \sum (b_n(x_i) - s_i)^2 \rightarrow \min_{b \in \mathcal{B}}$$

$$s_i = y_i - \alpha_{N-1}(x_i) - \text{тогда для ова обрета} \\ \text{ижеи огын приоритет}$$